Infraestrutura

> Versão do Python e ambiente virtual

```
humberto@humberto-linux:~/Documentos/PROJ/POS_INFINET/classificacao-nao-supervisionada$ source /home/humberto/Documentos/PROJ/POS_INFINET/classificacao-nao-supervisionada/venv/bin/activate
(venv) humberto@humberto-linux:~/Documentos/PROJ/POS_INFINET/classificacao-nao-supervisionada$ python --version
Python 3.10.6
```

requirements.txt

```
matplotlib==3.6.2
matplotlib-inline==0.1.6
numpy==1.24.1
pandas==1.5.2
scikit-learn==1.2.0
scipy==1.9.3
seaborn==0.12.2
```

Libs

Plot

In [ ]:
```
import matplotlib.pyplot as plt
import seaborn as sns
import matplotlib.cm as cm
```

Cluster

In [ ]:
```
from sklearn.decomposition import PCA
from sklearn.preprocessing import Normalizer, LabelEncoder
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_samples, silhouette_score
```

Data manipulation

In [ ]:
```
import pandas as pd
import numpy as np
import os
```

Data Request

In [ ]:
```
df = pd.read_csv('data/dataset.csv')
```

Escolha da base

1- Escolha uma base de dados para realizar o trabalho. Essa base será usada em um problema de clusterização.

> Dados Bancários de empréstimos

2- Escreva a justificativa para a escolha de dados, dando sua motivação e objetivos.

> Trabalhar com dados na área de finanças, buscando aumentar meus conhecimentos no ramo, tendo em vista meu campo de atuação em uma empresa do setor financeiro

3- Mostre através de gráficos a faixa dinâmica das variáveis que serão usadas nas tarefas de clusterização.

In [ ]:
```
df.describe()
```

Out[ ]:

	loan_amount	income	Credit_Score
count	1.486700e+05	139520.000000	148670.000000
mean	3.311177e+05	6957.338876	699.789103
std	1.839093e+05	6496.586382	115.875857
min	1.650000e+04	0.000000	500.000000
25%	1.965000e+05	3720.000000	599.000000
50%	2.965000e+05	5760.000000	699.000000
75%	4.365000e+05	8520.000000	800.000000
max	3.576500e+06	578580.000000	900.000000

In [ ]:
```
plt.xticks(rotation=70)
sns.barplot(data=df)
```

Out[ ]:
```
<AxesSubplot: >
```

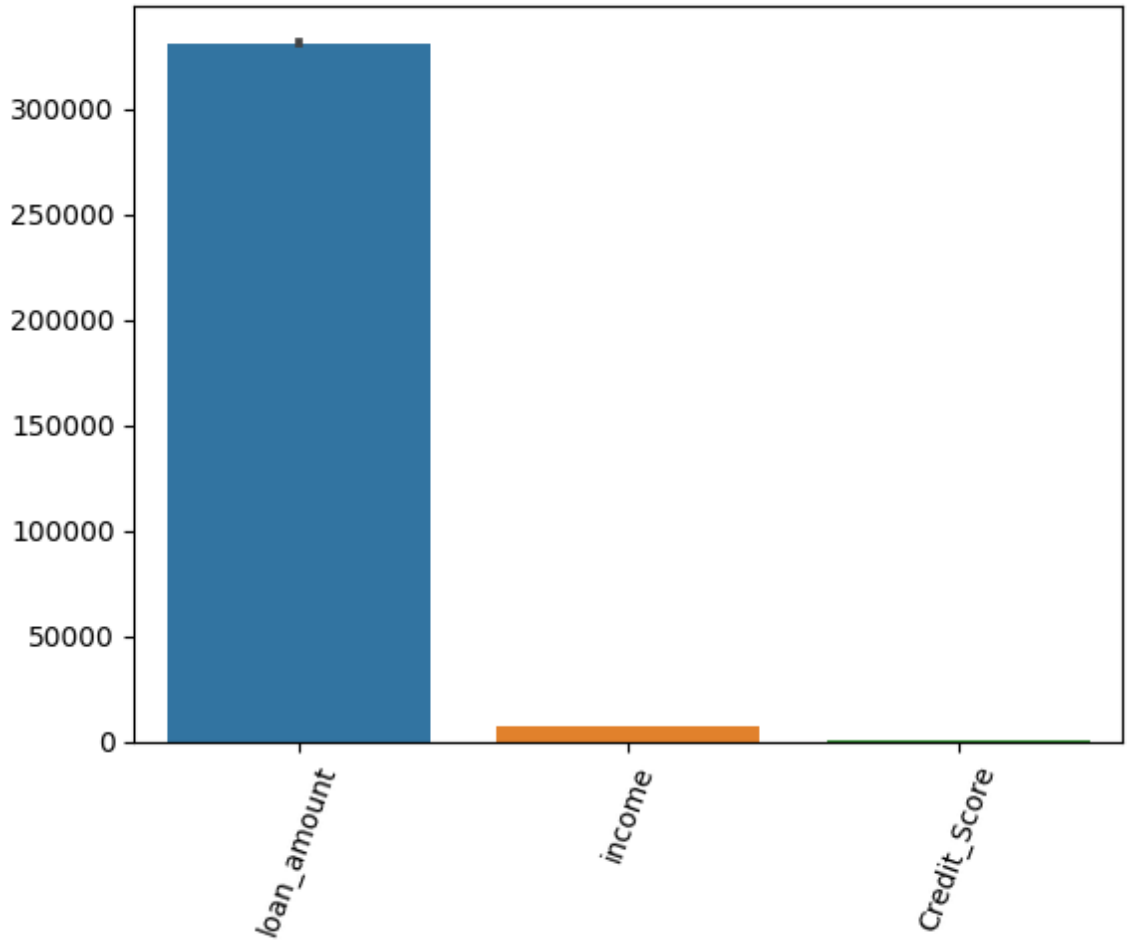

4- Analise os resultados mostrados. O que deve ser feito com os dados antes da etapa de clusterização?

> As variáveis possuem escalas diferentes, necessitando que seje feita a normalização dos dados, bem como a etapa de pre-processamento, a fim de tratar dados nulos, variáveis categóricas, limpeza de dados, análise gráfica, disposição dos valores, entre outros fatores necessários para que seja feita a correta realização da clusterização.

5- Realize o pré-processamento adequado dos dados. Descreva os passos necessários.

- Leitura dos dados;
- Análise de variáveis;
- Análise gráfica;
- Tratamento de variáveis categóricas;
- Tratamento dos dados nulos;
- Limpeza dos dados;
- Normalização

Clusterização

1- Com os resultados em mão, descreva o processo de mensuração do índice de silhueta. Mostre o gráfico e justifique o número de clusters escolhidos.

> Foi escolhido o número de cluster igual a 2, devido ao maior valor do índice de silhueta, bem como pelo comportamento da distribuição dos dados.

2 - Compare os dois resultados, aponte as semelhanças e diferenças e interprete.

> Kmeans utiliza a técnica do centroid, classificando os pontos de acordo com sua proximidade ao ponto central mais perto. É necessário atribuir o número de cluster manualmente. Dbscan é pautado na ideia de densidade, com uma distância máxima de classificação predefinida. Encontrando assim o número de cluster de forma automática.

3 - Escolha mais duas medidas de validação para comparar com o índice de silhueta e analise os resultados encontrados. Observe, para a escolha, medidas adequadas aos algoritmos.

> informação mútua e DBCV. O DBCV não foi possível de implementar, pois ocorreu erros com a biblioteca apresentada no curso, e não foi possível ajustar para os dados utilizados. A métrica informação mútua foi utilizada, porém não obtive resultado significativo, pois os dados não eram rotulados não sendo possível a comparação real, foi utilizado uma comparação entre os rotulos do DBSCAN e KMEANS, resultando em um score baixo, no qual significa que não houve forte associação entre os grupos.

4 - Realizando a análise, responda: A silhueta é um o índice indicado para escolher o número de clusters para o algoritmo de DBScan?

> Não, pois no algoritmo do Dbscan o número de cluster é definido automaticamente de acordo com a distância dos pontos.

Pre-Processamento

In [ ]:
```
for col in df.columns:
    print(col)
```

```
loan_amount
income
Credit_Score
age
```

In [ ]:
```
df.describe()
```

Out[ ]:

	loan_amount	income	Credit_Score
count	1.486700e+05	139520.000000	148670.000000
mean	3.311177e+05	6957.338876	699.789103
std	1.839093e+05	6496.586382	115.875857
min	1.650000e+04	0.000000	500.000000
25%	1.965000e+05	3720.000000	599.000000
50%	2.965000e+05	5760.000000	699.000000
75%	4.365000e+05	8520.000000	800.000000
max	3.576500e+06	578580.000000	900.000000

In [ ]:
```
df.dtypes
```

Out[ ]:
```
loan_amount       int64
income          float64
Credit_Score      int64
age              object
dtype: object
```

In [ ]:
```
df.nunique()
```

Out[ ]:
```
loan_amount      211
income          1001
Credit_Score     401
age                7
dtype: int64
```

In [ ]:
```
df.isna().sum()
```

Out[ ]:
```
loan_amount        0
income          9150
Credit_Score       0
age              200
dtype: int64
```

In [ ]:
```
df.dropna(inplace=True)
```

In [ ]:
```
def enconding(df, dumies=False):
    if dumies:
        return pd.get_dummies(df, columns=['age'])
    lb = LabelEncoder()
    df_encoding = df.copy()
    df_encoding['age'] = lb.fit_transform(df_encoding[['age']])
    return df_encoding

df_encoding = enconding(df)
```

```
/home/humberto/Documentos/PROJ/POS_INFINET/classificacao-nao-supervision
ada/venv/lib/python3.10/site-packages/sklearn/preprocessing/_label.py:11
6: DataConversionWarning: A column-vector y was passed when a 1d array w
as expected. Please change the shape of y to (n_samples, ), for example
using ravel().
  y = column_or_1d(y, warn=True)
```

In [ ]:
```
df_encoding
```

Out[ ]:

	loan_amount	income	Credit_Score	age
0	116500	1740.0	758	0
1	206500	4980.0	552	3
2	406500	9480.0	834	1
3	456500	11880.0	587	2
4	696500	10440.0	602	0
...	...	...	...	...
148665	436500	7860.0	659	3
148666	586500	7140.0	569	0
148667	446500	6900.0	702	2
148668	196500	7140.0	737	3
148669	406500	7260.0	830	2

139520 rows × 4 columns

In [ ]:
```
normalizer = Normalizer()
data_normalizer = normalizer.fit_transform(df_encoding)
df_normalizer = pd.DataFrame(data_normalizer)
df_normalizer
```

Out[ ]:

	0	1	2	3
0	0.999867	0.014934	0.006506	0.000000
1	0.999706	0.024109	0.002672	0.000015
2	0.999726	0.023315	0.002051	0.000002
3	0.999661	0.026015	0.001285	0.000004
4	0.999887	0.014988	0.000864	0.000000
...	...	...	...	...
139515	0.999837	0.018004	0.001509	0.000007
139516	0.999925	0.012173	0.000970	0.000000
139517	0.999879	0.015452	0.001572	0.000004
139518	0.999333	0.036312	0.003748	0.000015
139519	0.999838	0.017857	0.002041	0.000005

139520 rows × 4 columns

Diminuição da dimensionalidade

In [ ]:
```
pca = PCA(n_components=2)
principalComponents = pca.fit_transform(df_normalizer)

features = range(pca.n_components_)
plt.bar(features, pca.explained_variance_ratio_, color='black')
plt.xlabel('PCA features')
plt.ylabel('variance %')
```

```
plt.xticks(features)

PCA_components = pd.DataFrame(principalComponents)
```

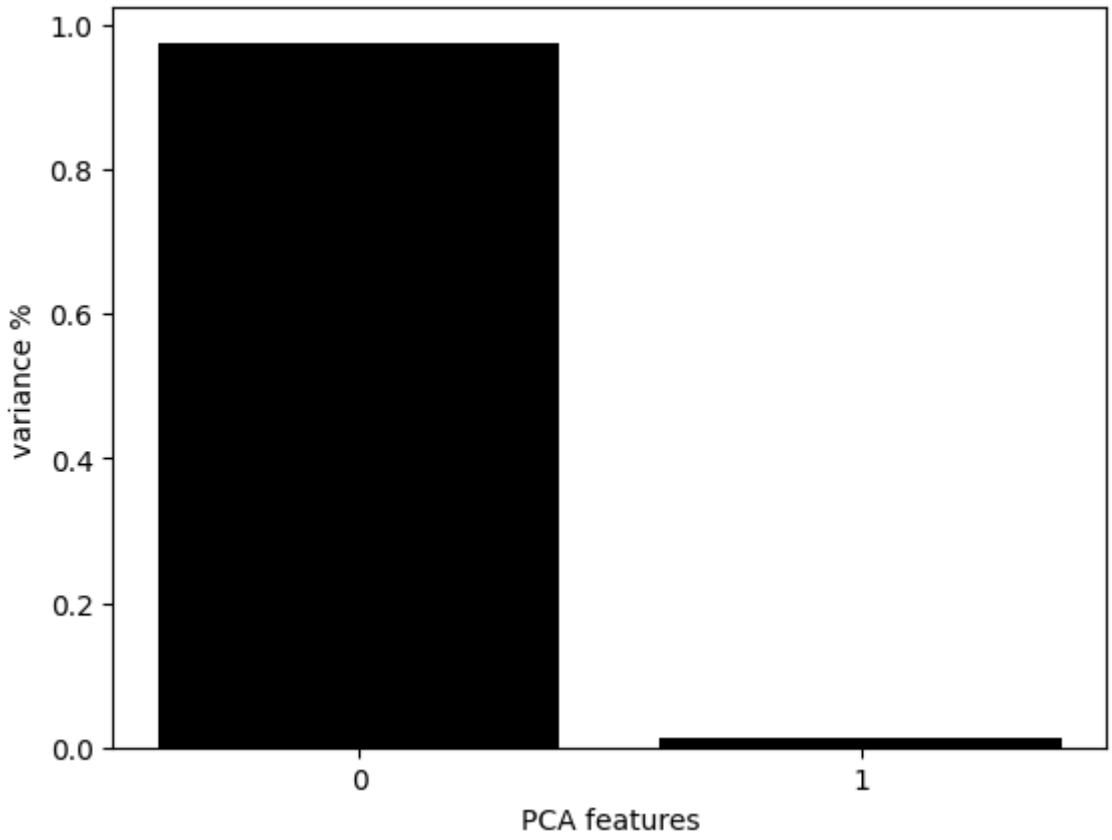

Cluster

In [ ]:
```
from sklearn.cluster import DBSCAN
from DBCV import DBCV
from sklearn.metrics.cluster import mutual_info_score
from scipy.spatial.distance import euclidean


class Clustering:

    def __init__(self, data: pd.DataFrame, range_n_clusters: list = [2]):
        self.X = data
        self.range_n_clusters = range_n_clusters
        self.n_clusters = None
        self.centers = None
        self.cluster_labels = None
        self.silhouette_avg = None
        self.sample_silhouette_values = None

    def start(self, type_method='kmeans'):
        if type_method == 'kmeans':
            for self.n_clusters in self.range_n_clusters:
                self.handle_kmeans()
                self.handle_silhouettes()
                self.handle_plot()
        else:
            self.handle_dbscan()
        self.handle_silhouettes()
```

```
        self.handle_plot()
        plt.show()

    def handle_kmeans(self):
        clusterer = KMeans(n_clusters=self.n_clusters, n_init=10, random_
        self.cluster_labels = clusterer.fit_predict(self.X)
        self.centers = clusterer.cluster_centers_

    def handle_dbscan(self):
        clusterer = DBSCAN(eps=0.1, min_samples=5)
        self.cluster_labels = clusterer.fit_predict(self.X)
        serie_labels = pd.Series(self.cluster_labels)
        index = []
        for label in serie_labels.unique():
            index.append(serie_labels[serie_labels == label].index.tolist
        self.centers = clusterer.components_[index]
        self.n_clusters = serie_labels.nunique()

    def handle_silhouettes(self):
        self.silhouette_avg = silhouette_score(self.X, self.cluster_label
        print(
            "For n_clusters =",
            self.n_clusters,
            "The average silhouette_score is :",
            self.silhouette_avg,
        )

        self.sample_silhouette_values = silhouette_samples(self.X, self.c

    def score_DBCV(self, type_method, n_cluster):
        self.n_clusters = n_cluster
        if type_method == 'kmeans':
            self.handle_kmeans()
        else:
            self.handle_dbscan()
        return DBCV(self.X, self.cluster_labels, dist_function=euclidean)

    def score_mutual_info(self, n_cluster):
        self.n_clusters = n_cluster
        self.handle_kmeans()
        label_kmeans = self.cluster_labels
        self.handle_dbscan()
        label_dbscan = self.cluster_labels
        return mutual_info_score(label_kmeans, label_dbscan)

    def handle_plot(self):
        fig, (ax1, ax2) = plt.subplots(1, 2)
        fig.set_size_inches(18, 7)
        ax1.set_xlim([-0.1, 1])
        ax1.set_ylim([0, len(self.X) + (self.n_clusters + 1) * 10])
        y_lower = 10
        for i in range(self.n_clusters):
            ith_cluster_silhouette_values = self.sample_silhouette_values

            ith_cluster_silhouette_values.sort()

            size_cluster_i = ith_cluster_silhouette_values.shape[0]
            y_upper = y_lower + size_cluster_i

            color = cm.nipy_spectral(float(i) / self.n_clusters)
```

```
            ax1.fill_betweenx(
                np.arange(y_lower, y_upper),
                0,
                ith_cluster_silhouette_values,
                facecolor=color,
                edgecolor=color,
                alpha=0.7,
            )
        ax1.set_title("The silhouette plot for the various clusters.")
        ax1.set_xlabel("The silhouette coefficient values")
        ax1.set_ylabel("Cluster label")
        ax1.axvline(x=self.silhouette_avg, color="red", linestyle="--")
        ax1.set_yticks([])
        ax1.set_xticks([-0.1, 0, 0.2, 0.4, 0.6, 0.8, 1])
        colors = cm.nipy_spectral(self.cluster_labels.astype(float) / sel
        ax2.scatter(
            # X[:, 0], X[:, 1], marker=".", s=30, lw=0, alpha=0.7, c=colo
            self.X.iloc[:, 0], self.X.iloc[:, 1], marker=".", s=30, lw=0,
        )

        ax2.scatter(
            self.centers[:, 0],
            self.centers[:, 1],
            marker="o",
            c="white",
            alpha=1,
            s=200,
            edgecolor="k",
        )
        for i, c in enumerate(self.centers):
            ax2.scatter(c[0], c[1], marker="$%d$" % i, alpha=1, s=50, edg

        ax2.set_title("The visualization of the clustered data.")
        ax2.set_xlabel("Feature space for the 1st feature")
        ax2.set_ylabel("Feature space for the 2nd feature")

        plt.suptitle(
            "Silhouette analysis for KMeans clustering on sample data wit
            % self.n_clusters,
            fontsize=14,
            fontweight="bold",
        )
```

Silhueta

Kmeans

In [ ]:
```
Clustering(PCA_components.sample(10000, random_state=0), [2,3,4,5]).start
```

```
For n_clusters = 2 The average silhouette_score is : 0.7484350804553982
For n_clusters = 3 The average silhouette_score is : 0.6893727094026102
For n_clusters = 4 The average silhouette_score is : 0.6106117766095601
For n_clusters = 5 The average silhouette_score is : 0.5532567133649307
For n_clusters = 5 The average silhouette_score is : 0.5532567133649307
```

Silhouette analysis for KMeans clustering on sample data with n_clusters = 2

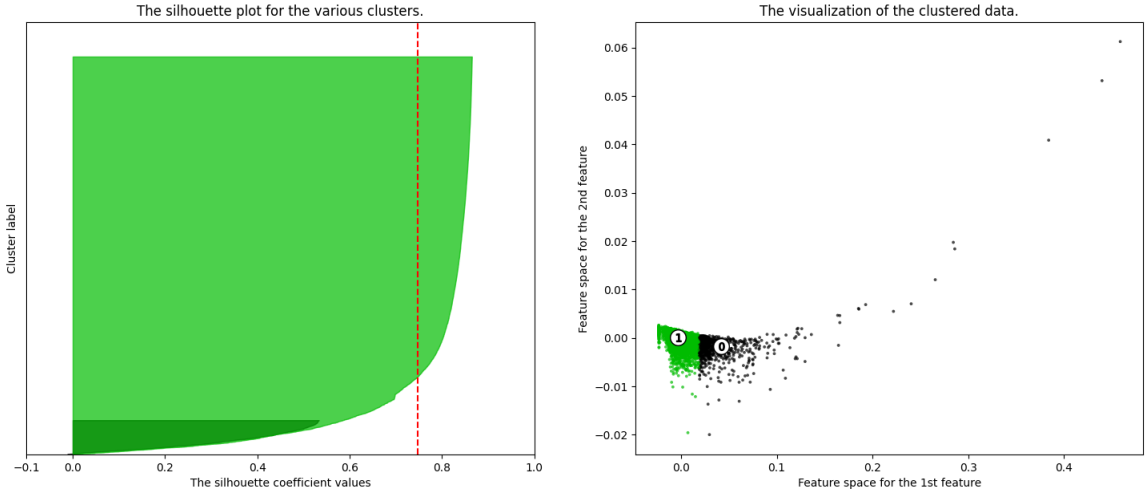

Silhouette analysis for KMeans clustering on sample data with n_clusters = 3

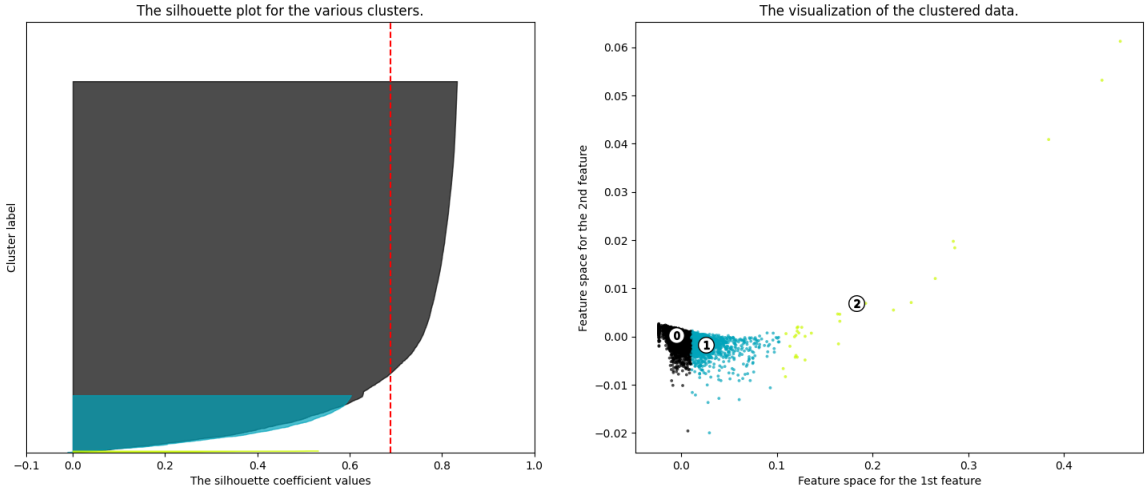

Silhouette analysis for KMeans clustering on sample data with n_clusters = 4

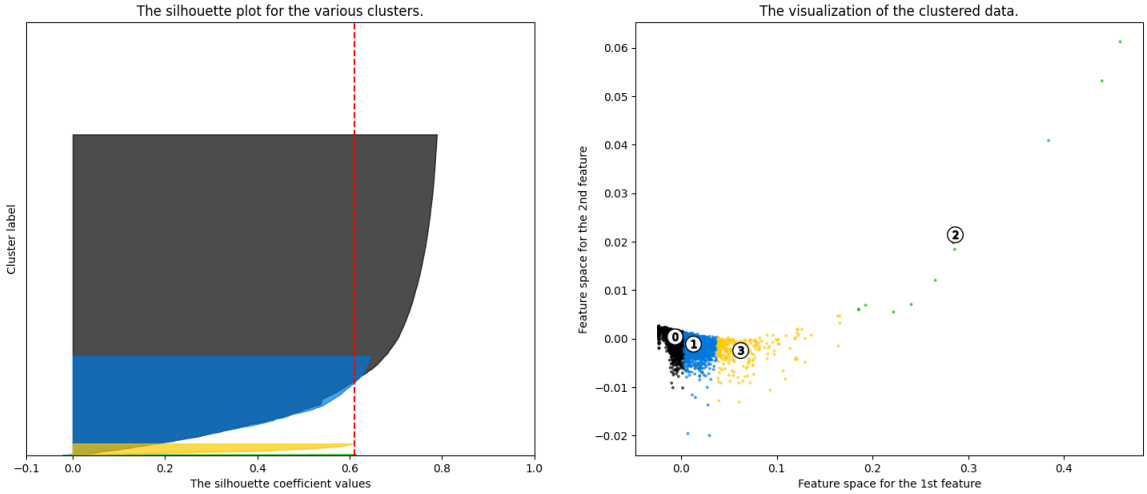

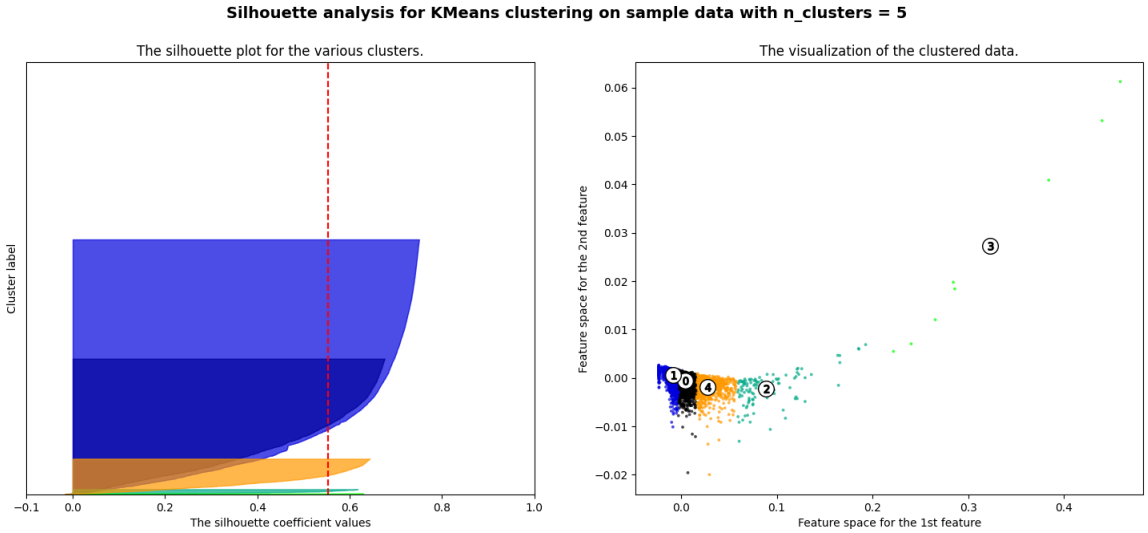

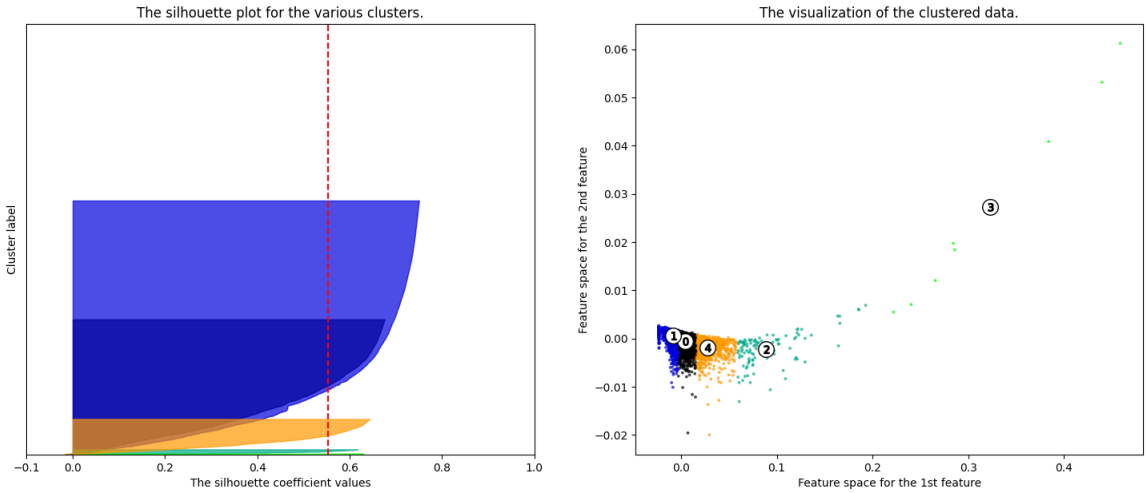

Dbscan

In [ ]:
```
Clustering(PCA_components.sample(10000, random_state=0), [2,3,4,5]).start
```

```
For n_clusters = 2 The average silhouette_score is : 0.965809951237512
```

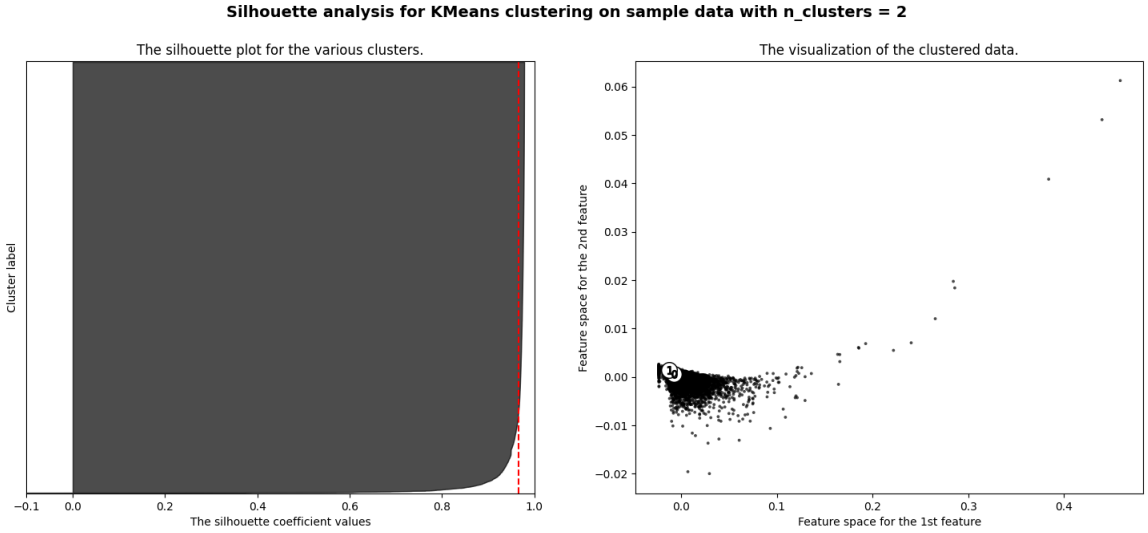

Informação mútua

In [ ]:
```
score_mutual_info = Clustering(PCA_components.sample(10000, random_state=

print(f'Score informação mútua: {score_mutual_info}')
```

```
Score informação mútua: 0.0007650768697802022
```

DBCV

In [ ]:
```
# score_kmeans = Clustering(PCA_components.sample(10000, random_state=0))
# score_dbscan = Clustering(PCA_components.sample(10000, random_state=0))

# print(f'Kmeans score DBCV: {score_kmeans}')
# print(f'Dbscan score DBCV: {score_dbscan}')score_kmeans = Clustering(PC
# score_dbscan = Clustering(PCA_components.sample(10000, random_state=0))

# print(f'Kmeans score DBCV: {score_kmeans}')
# print(f'Dbscan score DBCV: {score_dbscan}')

print('A classe informada no curso para DBCV está retornando erro para a
```

```
A classe informada no curso para DBCV está retornando erro para a implem
entação utilizada
```

Medidas de similaridade

---

1 - Um determinado problema, apresenta 10 séries temporais distintas. Gostaríamos de agrupá-las em 3 grupos, de acordo com um critério de similaridade, baseado no valor máximo de correlação cruzada entre elas. Descreva em tópicos todos os passos necessários.

Passo:

- Compara as séries em pares
- Mantém uma estática e a outra aplica um offset
- Calcula-se a correlação entre elas ao longo de todo o espaço de tempo adicionando o offset
- Registra o valor de correlção e o offset utilizado
- Identifica o maior valor de correlação e qual o offset foi utilizado
- Ao final da correlação cruzada teremos a maior similaridade para um offset específico
- Esse comparativo é feito entre todas as séries
- O valor do sinal do offset identifica os sinais como leader-follower
- Separação das séries com maior sincronia

2 - Para o problema da questão anterior, indique qual algoritmo de clusterização você usaria. Justifique.

- Dbscan, pois a série temporal tende a comportamento de clusters com forma arbitrária, e não convexa, dificultando a classificação pelo método do Kmeans. Para

esse tipo de dado o dbscan teria melhor desempenho, devido sua característica de classificação por vizinhança.

3 - Indique um caso de uso para essa solução projetada.

- Preço de ações

4 - Sugira outra estratégia para medir a similaridade entre séries temporais. Descreva em tópicos os passos necessários.

> Outra estratégia seria a utilização do método DTW.

Passos:

- Compara as séries em pares
- Faz a corrensapondencia dos sinais pelas amplitudes
- Montagem da matrix de distância aplicando as regras de custo do algorítimo
- A matriz resultará no cálculo do custo mínimo para os dois sinais terem a maior sincronia
- Pela matrix é possível identificar o leader-follower entre os sinais
- Separação das séries com maior sincronia